

机器学习与云计算：分布式和 SaaS 解决方案综述

Daniel Pop

Institute e-Austria Timișoara, soara Bd. Vasile P
Învan No. 4, 300223 Timișoara, România
a E-mail: danielpop@info.uvt.ro

摘要

将流行的机器学习算法应用于海量数据，给 ML 从业者带来了新的挑战。传统 ML 库并不能很好地支持巨大数据集的处理，因此需要新的方法。使用 MapReduce、Cassandra 或 Dryad 等现代并行计算框架进行并行化日益流行并获得认可，由此产生了构建在这些框架之上的新 ML 库。我们将简要介绍最突出的工业界和学术界成果，例如 Apache Mahout TM、GraphLab 或 Jubatus。

我们将考察云计算范式如何影响 ML 领域。第一个方向是部署在云端的流行统计工具和库（R system、Python）。第二类产品通过插件增强现有工具，使用户能够在云中创建 Hadoop 集群并在其上运行作业。接下来是 ML 算法的分布式实现库，以及用于数据分析和数据挖掘的复杂系统的本地部署。本综述关注的最后一种方法是作为 Software-as-a-Service 的 ML，若干 BigData 初创公司（以及大型公司）已经将其解决方案推向市场。

1 引言

鉴于公司、产业和科学领域收集并可用的数据量巨大增长，分析这类数据的技术变得越来越重要。今天，需要分析的数据不再局限于传感器数据和经典数据库，而是越来越多地包括文本文档和 Web-

网页（文本挖掘、Web 挖掘）、空间数据、多媒体数据、关系数据（分子、社交网络）。分析工具使最终用户能够收获埋藏在大量结构化和非结构化数据中的有意义模式。分析大数据集让用户有能力识别新的收入来源，发展忠诚且有利润的客户关系，并更高效、更具成本效益地运营整个组织。

知识发现和机器学习研究将计算机科学的经典问题（高效算法、软件系统、数据库）与人工智能和统计学元素结合起来，并延伸到面向用户的问题（可视化、交互式挖掘）。

尽管二十多年来，Teradata、Oracle 或 Netezza 等并行数据库产品已经提供了实现 ML-DM 算法并行实现的手段，但用 SQL 代码表达 ML-DM 算法是一项复杂且难以维护的任务。此外，这些产品的大规模安装成本高昂，在大多数情况下并非可负担的选择。从关系模型转向其他替代方案的另一个驱动因素是数据的新性质。直到大约五年前，大多数数据本质上仍是事务性的，由能够轻松放入关系数据库行和列中的数值或字符串数据组成。此后，结构化数据近似线性增长，而非结构化数据（例如音频和视频）以及半结构化数据（例如 Web 流量数据、社交媒体内容、传感器生成的数据等）呈指数增长（见图 1）。大多数新数据要么是半结构化格式，即由头部后接文本字符串组成，要么是纯非结构化数据（照片、视频、音频）。后者文本内容有限，更难解析和分析，而半结构化数据催生了大量非关系数据存储（NoSQL 数据存储）解决方案，这些方案专为处理海量数据而设计。因此，过去 5 年已经




图 1. 数据增长趋势

促使研究人员转向使用这些新平台来并行化 ML-DM，例如 NoSQL 数据存储、分布式处理环境（MapReduce）或云计算。

在这一点上，值得回顾 Platfora 联合创始人 Ben Werther [18] 对当今大数据处理提出的一个形象比喻：

“用“工业革命”的说法，我们正处于大规模生产之前的手工业前工业时代

■

这相当于我们需要请一位专业铁匠为餐桌锻造叉子和勺子。

”

机器学习本质上是一项耗时任务，因此已有大量工作用于加快执行时间。云计算范式和云提供商被证明是加速机器学习平台的有价值替代方案。因此，R、Octave、Python 等流行统计工具环境也进入了云端。将它们与云提供商集成主要有两个方向：在云中创建集群并用统计工具对其进行引导配置，或者用插件增强统计环境，使用户能够在云中创建 Hadoop 集群并在其上运行作业。

R、Octave、Maple 及类似环境为数据分析提供底层基础设施，一旦由云提供商加以利用，就可应用于大型数据集。机器学习位于其上层，通过从数据中自动推断“知识模型”，帮助统计背景较少或没有统计背景的客户从海量数据中检索有用知识。为支持这种需求，大量初创公司涌现，其中一些仍处于保密

尚未进入成熟模式的公司，过去 5 年中已经可以看到它们向客户提供机器学习服务或大数据分析服务。这些计划可以是 PaaS/SaaS 平台，也可以是可部署在私有环境中的产品。

回顾文献和市场，我们可以得出结论：ML-DM 有多种形态。我们将这些方法分为 5 个不同类别：

- 来自云端的机器学习环境会在云中创建计算机集群，并用统计工具对其进行引导配置。⇒ 第 3 节。
- 机器学习工具插件 - 使用插件增强统计工具，使用户能够在云中创建 Hadoop 集群并在其上运行 ML 作业。⇒ 第 4 节。
- 分布式机器学习库 - 面向分布式环境（Hadoop、Dryad 等）的 ML 算法并行化实现集合。⇒ 第 5 节。
- 复杂机器学习系统 - 需要安装在私有数据中心（或云端）并提供高性能数据挖掘和分析的产品。⇒ 第 6 节。
- 面向机器学习的 Software as a Service 提供商 - 允许客户通过 Web 服务访问 ML 算法的 PaaS/SaaS 解决方案。⇒ 第 7 节。

本文其余部分安排如下：下一节介绍相似的近期研究，随后 5 节分别讨论上述识别出的一个特定类别。论文以结论和未来计划结束。

2 相关研究

自 1995 年以来，已有许多用于共享或分布式系统中 ML-DM 算法并行化的实现被提出。关于全面研究，读者可参考近期综述 [17]。我们的工作聚焦于允许大规模、分布式实现最先进 ML-DM 算法的框架、工具包和库。在这方面，我们提及一本近期关于大规模机器学习的书 [1]，其中既介绍了 DryadLINQ 或 IBM PMLT 等用于高度可扩展 ML 实现的通用框架，也介绍了这些平台上 ML 技术的具体实现，例如集成决策树、SVM、k-Means 等。它包含来自工业界领导者（Google、HP、

IBM、Microsoft）以及学术界（Berkeley、NYU、University of California 等）的贡献。

S. Charrington [3]、W. Eckerson [4] 和 D. Harri s [5] 等人的近期文章评述了不同的大规模 ML 解决方案提供商，这些提供商大多基于 Hadoop 基础设施，试图提供更好的工具和技术，以推动新兴的大数据产业向前发展。它们旨在改进用户体验，提供产品推荐或网站优化，并可应用于金融、电信、零售、广告或媒体。

3 来自云端的机器学习环境

这一类别的提供商使用 Amazon EC2、Rackspace 等公共云提供商提供计算机集群，并预装统计软件，首选包包括 R system、Octave 或 Mapple。这些解决方案向客户提供云端可扩展的高性能资源，使客户无需安装和管理自己的集群。

Cloudnumbers.com 1 使用 Amazon EC2 2 提供商来搭建预装科学计算软件的计算机集群，例如 R system、Octave 或 Mapple。客户可通过 Web 界面创建自己的工作区、配置和监控集群、上传数据集或连接公共数据库。在云提供商默认功能之上，Cloudnumbers 通过为数据传输和存储提供安全加密来提供高安全标准。总体而言，这是一个云端 HPC 平台，易于创建且维护省力。

CloudStat 3 是一个基于 R system 构建的云集成开发环境，并通过两类用户界面暴露其功能：面向 R 语言有经验用户的控制台，以及应用程序 - 为没有 R 编程技能的用户设计的基于点击式表单的 R 界面。还有一个 CloudStat AppStore，用户可以从不断增长的仓库中选择应用。

Opani 4 提供与 Cloudnumbers.com 类似的服务，但还帮助客户根据其需求确定集群规模：数据大小以及处理这些数据的时间范围。它们使用 Rackspace 5 基础设施，并支持 R system、Node 和 Python 等环境，捆绑

并包含 map/reduce、可视化、安全和版本控制包。数据分析过程的结果在 Opani 中称为 dashboard，可轻松从桌面或移动设备进行可视化和共享。

这一类别的方法是强大且灵活的解决方案，为用户提供在云端开发复杂 ML-DM 应用的可能性。用户无需为科学计算配置自己的分布式环境，同时仍能使用自己喜欢的环境。另一方面，这些工具的用户需要具备丰富的编程经验和扎实的统计学知识。也许正因为受众有限，这一类别中的稳定提供商少于其他类别，其中一些（例如 CRdata.org）在启动后不久便停止运营。

4 机器学习工具插件

在这一类别中，统计应用（例如 R system、Python）通过插件扩展，使用户能够在云中创建 Hadoop 集群，并在其上对大型数据集运行耗时作业。多数关注点集中在 R 上，已有若干扩展可用；相比之下，直到最近，对 Python 支持分布式处理的投入较少。本节将介绍若干面向 R 和 Python 的解决方案。

RHIPE 6 是一个 R 包，它为 R 实现了 map/reduce 框架，使用户能够从 R 环境内部访问 Hadoop 安装。使用特定的 R 函数，用户可以启动在 Hadoop 集群上执行的 map/reduce 作业，然后从 HDFS 取回结果。

Snow 7 [16] 及其变体（snowfall、snowFT）实现了一个框架，能够表达一类重要的并行计算，并且易于在 R 等交互式环境中使用。它支持三类集群：基于 socket 的集群、MPI 和 PVM。

Segue for R 8 项目使用户更容易从 R 环境内部在 Amazon Elastic Map Reduce 9 的弹性集群上运行 map/reduce 作业。

Anaconda 10 是 Continuum Analytics 11 提供的 Python 可扩展数据分析与科学计算方案。它是一组软件包（NumbaPro -

1 <http://cloudnumbers.com>
2 <http://aws.amazon.com/ec2/>
3 <http://cs.croakun.com>
4 <http://opani.com>
5 <http://rackspace.com>

6 <http://www.stat.purdue.edu/~sguha/rhipe/doc/html/index.html>
7 http://cran.r-project.org/web/packages/available_packages_by_name.html
8 <http://code.google.com/p/segue/>
9 <http://aws.amazon.com/elasticmapreduce/>
10 <https://store.continuum.io/cshop/anaconda>
11 <http://continuum.io>

快速、多核并支持 GPU 的计算, IOPro - 快速数据访问, 以及 wiseRF Pine - Random Forest 的多核实现), 可支持大规模数据管理、分析、可视化等。它可以作为完整的 Python 发行版安装, 也可以接入现有安装。

由于 R system 在 ML-DM 从业者中很受欢迎, 并在过去 2 年中成为此类任务的首选工具 [15, 10], 近期已有许多努力将耗时流程并行化到可扩展的分布式框架 (Hadoop) 上。相比云端 ML, 这种方法更受偏好, 因为它可以复用研究机构或工业 (私有) 数据中心的现有基础设施。据我们所知, 除 Mathematica 的 HadoopLink 12 外, 对于 Mathematica、Maple 或 Matlab/Octave 等相关数学工具并没有类似方法。这一类解决方案的受众同样需要在编程语言、数学、统计学和机器学习算法方面具备很高资质。

5 分布式机器学习库

这一类别提供可在各种分布式设置 (Hadoop、Dryad、MPI) 上运行的复杂库。它们允许用户使用开箱即用的算法, 或实现自己的算法, 并在计算机集群上以并行模式运行。这些解决方案不集成也不使用统计/数学软件, 而是提供自包含的软件包, 其中包含经过优化的、最先进的 ML-DM 方法和算法。

Apache Mahout TM 13 [12] 是一个 Apache 项目, 旨在 Hadoop 平台 [20] 上提供分布式或其他可扩展机器学习算法的自由实现。它最初是一组相互独立的“无 Hadoop”组件, 例如“Taste”协同过滤。其目标是构建可扩展的机器学习库, 其中可扩展具有更广泛的含义:

- 可扩展到相当大的数据集。Mahout 用于聚类、分类和基于批处理的协同过滤的核心算法基于 Apache Hadoop [20], 使用 map/reduce 范式实现。不过, 它并不将贡献限制为基于 Hadoop 的实现: 也欢迎可在单节点或非 Hadoop 集群上运行的贡献。核心库经过高度优化, 以允许

也能为非分布式算法提供良好性能。

- 可扩展以支持各种业务场景。Mahout 采用商业友好的 Apache Software license 发布。

- 可扩展的社区。Mahout 的目标是建立一个充满活力、响应迅速且多元化的社区, 以促进关于项目本身以及潜在用例的讨论。

目前 Mahout 主要支持四类用例:

- 推荐挖掘会利用用户行为, 并据此尝试找到用户可能喜欢的条目
- 聚类会接收例如文本文档, 并将其分组成主题相关的文档组
- 分类会从已有分类文档中学习特定类别的文档是什么样的, 并能够将未标注文档分配到 (希望是) 正确的类别。

- 频繁项集挖掘接收一组条目集合 (查询会话中的术语、购物车内容), 并识别哪些单个条目通常一起出现。

与 Apache Giraph 14 等图处理平台计划的集成正在积极讨论中。该项目背后有一个活跃社区。

GraphLab 15 [11] 是云端 ML-DM 框架。虽然 MapReduce 等高级数据并行框架简化了大规模数据处理系统的设计和实现, 但它们并不能自然或高效地支持许多重要的数据挖掘和机器学习算法, 并可能导致学习系统低效。为帮助填补这一关键空白, GraphLab 是一种抽象, 能够自然表达异步、动态、图并行计算, 同时确保数据一致性, 并在共享内存和分布式环境中实现高度并行性能。它用 C++ 编写, 并能直接访问 Hadoop Distributed File System (HDFS) [20] 中的数据。作者报告称其性能比类似方法高出数个数量级。

DryadLINQ 16 [19, 2] 是 Microsoft 开发的 LINQ (Language INtegrated Query 17 子系统

14 <http://incubator.apache.org/giraph/>

15 <http://graphlab.org>

16 <http://research.microsoft.com/en-us/projects/DryadLINQ/>

17 <http://msdn.microsoft.com/netframework/future/linq/>

12 <https://github.com/shadanan/HadoopLink>

13 <http://mahout.apache.org>

Research 之上，它基于 Dryad [9]，后者是执行数据并行应用的通用架构。它支持继承自 Dryad 的基于 DAG 的抽象，用于实现数据处理算法。DryadLINQ 程序是由 LINQ 表达式组成的顺序程序，这些表达式对数据集执行任意无副作用转换，并且可以使用标准 .NET 开发工具编写和调试。DryadLINQ 系统会自动且透明地将程序中的数据并行部分转换为分布式执行计划，并将其传递给 Dryad 执行平台，由该平台确保计划高效可靠地执行。作者展示了执行时间随作业所用计算机数量近似线性扩展。虽然基于 DAG 的抽象允许丰富的计算依赖，但它并不能自然表达 ML-DM 中常见的迭代、数据并行、任务并行以及动态数据驱动算法。

Jubatus 18 [8] 始于 2011 年 4 月，是一个在线/实时机器学习平台，基于分布式架构实现。与 Mahout TM 相比，它是一个下一步平台，提供流处理和在线学习。在在线 ML 中，模型会随着每个快速到来的数据样本持续更新，且算法不占用大量内存。它不需要数据存储，也不需要数据共享；只需要模型混合。它支持分类问题（Passive Aggressive (PA)、Confidence Weighted Learning、AROW）、基于 PA 的回归、最近邻（LSH、MinHash、Euclid LSH）、推荐、异常检测（基于 NN 的 LOF）和图分析（最短路径、PageRank）。为了高效支持在线学习，Jubatus 在本地模型上执行更新，然后每台服务器传输其模型差异，这些差异会被合并并分发回所有服务器。由于所有服务器的工作，混合模型会逐步改进。

IBM Parallel Machine Learning Toolbox 19 [13] (PMLT) 是 IBM Haifa Lab 的机器学习小组与 IBM Watson Lab 的数据分析部门共同努力的成果，提供在多处理器环境或多线程机器上执行数据挖掘和机器学习算法的工具。该工具箱包含两个主要组件：一个用于运行用户自有机器学习算法的 API，以及若干预编程算法，这些算法既可作为示例，也可用于比较。预编程算法包括 Support Vector Machine (SVM) 分类器的并行版本、线性回归、

变换回归、最近邻、k-means、fuzzy k-means、kernel k-means、PCA 和 kernel PCA。PML 工具箱的主要优势之一是能够在多种操作系统和平台上运行，从多核笔记本电脑到 BlueGene 等超级计算机。这是因为该工具箱包含一个并行化基础设施，将并行通信、控制和数据访问与学习算法实现完全分离。这种方法使学习算法设计者能够专注于算法问题，而无需关心底层并行化问题。它还使学习算法能够部署在多种硬件架构上，以串行或并行方式运行，而无需更改任何算法代码。该工具箱使用流行的 MPI 库作为运行基础，并用 C++ 编写。尽管我们努力获取该项目的最新消息，但除了 [1] (2012) 中的一个章节外，自 2007 年以来未发现该项目有近期活动。另一方面，该工具箱适用于并行环境，而不适用于分布式环境。

NIMBLE [6] 是 Parallel Machine Learning Toolbox 的后续项目，也由 IBM Research Labs 开发。它暴露了一个多层框架，开发者可以将其 ML-DM 算法表示为任务。随后任务被传递到下一层，即架构无关层，该层由一个任务 DAG 队列以及展开该队列的工作线程池组成。再下一层是架构相关层，它将上层的通用实体转换为各种运行时。目前，NIMBLE 仅支持在 Hadoop 平台 [20] 上执行。Dryad [9] 等其他平台也是良好候选，但尚未支持。该框架的优势包括：

- 更高层次的抽象，隐藏大多数分布式和并行编程范式（MR、MPI 等）的底层控制和编排细节，使程序员能够使用可复用的（串行和并行）构建块来组合并行 ML-DM 算法

- 可移植性：通过为架构相关层提供特定实现，同一代码可以在各种分布式运行时上执行

- 效率和可扩展性：由于任务 DAG 和协同调度引入的优化，[6] 中针对 Hadoop 运行时给出的结果显示，随着数据集大小和维度增加，加速比有所提升

。

18 <http://jubat.us/>

19 https://www.research.ibm.com/haifa/projects/verification/ml_toolbox/index.html

SystemML [7] 与 NIMBLE 和 PMLT 一样由 IBM Research labs 开发，它提出了一种类似 R 的语言（Declarative Machine Learning language），包含线性代数原语，并展示了如何将其优化并编译到 MapReduce。它们报告了在三种 ML 算法（Group Nonnegative Matrix Factorization、Linear regression、PageRank）上，针对不同数据和 Hadoop 集群规模的大量性能评估。

表 5 汇总了所研究的平台。可以注意到 Java 是首选环境，这是由于 Hadoop 作为分布式处理模型被广泛采用和使用。好消息是，大多数活跃且有生命力的解决方案都是开源的。这一类产品的目标受众是需要针对 ML-DM 问题获得快速、可扩展分布式解决方案的程序员、系统开发人员和 ML 专家。

6 复杂机器学习系统

本节介绍若干商业智能和数据分析解决方案，它们共享一组共同特征：(i) 都可部署在本地或云端集群上，(ii) 提供丰富的图形工具，用于分析、探索和可视化大量数据，(iii) 暴露的 ML-DM 功能相当有限，通常局限于预测模型，以及 (iv) 使用 Apache Hadoop [20] 作为处理引擎和/或存储环境。在数据如何集成和处理、支持的数据源或系统复杂性方面存在差异。以下是最知名的一些：

Kitenga Analytics 20 最近被 Dell 收购，是一个原生 Hadoop 应用，提供可视化 ETL、基于 Apache Solr 21 的搜索、自然语言处理、基于 Apache Mahout 的数据挖掘以及高级可视化能力。它是一个面向高级分析师的大数据环境，这些分析师需要一个强大的分析工具箱，且所有功能都来自易用界面，该界面不要求理解复杂编程或 Apache Hadoop 栈本身。

Pentaho Business Analytics 22 为大数据分析提供完整解决方案，支持分析过程的所有阶段，从预处理到高级数据探索和可视化。它提供 (i) 完整的可视化设计工具，以加速数据准备-

建模，(ii) 来自 NoSQL 和关系数据库的数据集成，(iii) 在 Hadoop 平台 [20] 上的分布式执行，(iv) 即时和交互式分析（无代码、无 ETL (Extract, Transform, Load)），以及 (v) 商业分析平台：数据发现、探索、可视化和预测分析。Pentaho 解决方案的主要特征包括：

- 基于 MapReduce 的数据处理
 - 可针对不同 Hadoop 发行版（如 Cloudera、Hadoop 等）进行配置
 - 数据可加载并处理到 Hadoop HDFS、HBase 23 或 Hive 24 中
 - 支持 Pig 脚本
 - 原生支持大多数 NoSQL 数据库，例如 Apache Cassandra、DataStax、Apache HBase、MongoDB、10gen 等。
 - 通过与原生 SQL 方言和并行批量数据加载器的深度集成，为分析数据库（如 Teradata、monetdb、Netezza 等）启用性能优化的数据分析、报告和数
- 据集成
- 与 LexisNexis Risk Solutions 25 的 HPCC (High Performance Computing Cluster) 集成
 - 从/向 PMML (Predictive Modeling Markup Language) 导入/导出
 - Pentaho Instaview，一个可视化应用，用于缩短部署数据分析解决方案所需时间，并帮助新手用户通过三个简单步骤洞察其数据：选择数据源，自动准备分析数据，以及可视化和探索构建出的模型。
 - Pentaho Mobile - 面向 iPad 的应用，为业务用户提供交互式商业分析

其生态系统由若干强大系统组成，每个系统本身都是一个复杂项目：

Pentaho BI Platform/Server，BI 平台是一个提供认证、日志、审计和规则引擎等核心服务的框架；它还有一个解决方案引擎，用于集成所有其他系统（报表、分析、集成和数据挖掘）；BI Server 是该平台最知名的实现，其功能是基于 Web 的报表

20 <http://www.quest.com/news-release/quest-software-expands-its-big-data-solution-with-new-hadoop-connection-102012818658.aspx>

21 <http://lucene.apache.org/solr/>

22 <http://www.pentaho.org>

23 <http://hbase.apache.org>

24 hive.apache.org

25 <http://hpccsystems.com>

管理系统、应用程序集成服务器和轻量级工作流引擎。

Pentaho Reporting 基于 JFreeReport，是一套开源工具 - Pentaho Report Designer、Pentaho Reporting Engine、Pentaho Reporting SDK 以及与整个 Pentaho BI Platform 共享的通用报表库 - 允许用户从多种来源创建关系型和分析型报表，并以多种格式（HTML、PDF、Excel 等）输出结果。

Pentaho Data Integration (Kettle) 使用元数据驱动的方法，在直观的图形化拖放设计环境中提供强大的 ETL 能力；

Pentaho Analysis Service (Mondrian) 是一个 Online Analytical Processing (OLAP) 服务器，支持实时数据分析

Pentaho Data Mining (Weka) 是一组用于分类、回归、聚类 and 关联规则的机器学习算法；

Platfora 26 提供内存商业智能，无需单独的数据仓库或 ETL。其基于 HTML5 的可视化界面允许业务用户分析数据。结果可以在用户之间轻松共享。它依赖 Hadoop 集群，该集群既可安装在本地，也可安装在云提供商（Amazon EMR 和 S3）上。它主要关注 BI 功能，例如精细的可视化类型（图表、绘图、地图）或切片与切块操作，但也提供预测分析框架。

Skytree Server 27 是一个通用机器学习和数据分析系统，支持来自关系数据库、Hadoop 系统或平面文件的数据，并提供连接常见统计包和 ML 库的连接器。支持的 ML 方法包括：Support Vector Machine (SVM)、Nearest Neighbor、KMeans、Principal Component Analysis (PCA)、Linear Regression、2-point correlation 和 Kernel Density Estimation (KDE)。Skytree Server 可连接 Web 服务或统计和 ML 库（R、Weka）等分析前端，用于数据可视化。其部署选项包括云提供商，或基于 Linux 机器的专用集群。它还通过一个简单公式（Analytics Requirements Index）支持客户估算所需集群规模。

Wibidata 28 是一个基于 Apache 开源软件栈的复杂解决方案，将 Hadoop、HBase 和 Avro 与专有组件结合。WibiData 的机器学习库提供

用于立即开始构建复杂数据处理流水线的工具。WibiData 还提供图形工具，可将数据从其分布式数据仓库导出到任何关系数据库 [21]。为简化使用 Hadoop 的数据处理，WibiData 引入了 producers 和 gatherers 的概念：producers 是更新表中某一行的计算函数，gatherers 则弥合 WibiData 表与 Hadoop MapReduce 引擎处理的键值对之间的差距。

我们知道，无法覆盖商业智能和大数据分析领域的所有解决方案提供商。我们试图覆盖那些也在其应用中提供 ML 组件的厂商；许多其他只关注大数据分析的厂商，如 Alteryx、SiSense、SAS 或 SAP，则未纳入本综述。这一类别的解决方案主要面向业务用户，他们需要快速、轻松地从数据中提取洞察，因此适合计算机或统计背景较少的用户。

7 面向机器学习的 Software as a Service 提供商

本节聚焦于面向机器学习问题的 platform-as-a-service 或 software-as-a-service 提供商。它们主要通过 RESTful 接口提供服务，在某些（少数）情况下，解决方案也可以安装在本地（Myrrix），这与上一节主要可部署在私有数据中心的系统形成对比。在这些系统所处理的 ML 问题类别中，预测建模最受青睐（BigML、Google Prediction API、Eigendog）。我们未将 Hadoop 上 SQL 解决方案（例如 Cloudera Impala、Hadapt、Hive）的提供商纳入本研究，因为它们的主要目标并非 ML-DM，而是使用 Hadoop 的分布式架构对关系数据进行快速、弹性且可扩展的 SQL 处理。

BigML 29 是一种面向机器学习的 SaaS 方法。用户可以设置数据源，创建、可视化和共享预测模型（仅支持决策树），并使用模型生成预测。所有操作都可通过 Web 界面完成，也可通过 REST API 以编程方式完成。

BitYota 30 是一家年轻的初创公司（2012），是 Big Data 仓储解决方案的 SaaS 提供商。在集成来自不同来源（关系型、NoSQL、HDFS）的数据之上，它还允许客户运行 SQL92 中的统计和汇总查询、标准 R 统计以及用 JavaScript、Perl 或

26 <http://platfora.com>

27 <http://skytree.net>

28 <http://wibidata.com>

29 <http://bigml.com>

30 <http://bityota.com>

在并行分析引擎上运行 Python。结果通过与流行 BI 工具和 dashboard 集成来可视化。

Precog 31 拥有一个更精细的 SaaS 解决方案，由 Precog database、Quirrel language、ReportGrid 和 LabCoat 工具组成。Precog 的核心是一个原创的（不基于 Hadoop，也不基于其他 NoSQL）、无模式、列式数据库，专为存储和分析半结构化的测量数据而设计，例如事件（用户点击、参与和购买）、传感器数据、活动流数据、事实以及其他不需要可变更的数据。Precog 的功能通过 REST API 暴露，但也提供 Java Script、Python、PHP、Ruby、Java 或 C# 的客户端库。LabCoat 是用于创建和管理 Quirrel 查询的 GUI 工具。Quirrel 是一种高度表达性的数据分析语言，使用户能够轻松地在数据库内部对任何类型的测量数据执行分析、统计和机器学习。结果可用 JSON 或 CSV 格式获得。ReportGrid 是一个 HTML5 可视化引擎，可交互式或以编程方式构建报表和图表。

Google Prediction API 32 是 Google 的云端机器学习工具，可帮助分析你的数据。它与存储训练数据的 Google Cloud Storage 33 紧密连接，并使用 RESTful 接口提供服务，客户端库允许程序员从 Java、JavaScript、.NET、Ruby、Python 等连接。第一步需要从数据训练模型，目前支持的模型包括分类和回归。模型构建后，可以查询该模型以获得对新实例的预测。向已训练模型添加新数据称为 Streaming Training，并且也得到了良好支持。近期添加了 PMML 预处理功能，即 Prediction API 支持按照 PMML 4.0 语法指定的 PMML 转换对你的数据进行预处理；但不支持导入包含数据的完整 PMML 模型。创建的模型可以作为托管模型在市场中共享。

EigenDog 34 是一种可扩展预测建模服务，托管在 Amazon EC2（用于计算）和 S3（用于数据和模型存储）平台上。它从 Weka 的 ARFF 格式数据构建决策树模型。借助 API 或供应商提供的开源库，模型可以二进制格式下载并集成到用户应用中。

Metamarkets 35 自称是 Data Science-as-a-Service 提供商，帮助用户从其大型数据集中获得洞察。它们为最终用户提供执行快速、临时性数据调查的可能性，以基于统计模型，以直观、交互和协作的方式发现新的独特异常，并发现数据流中的趋势。它们专注于业务人员，这些人员对统计学和机器学习了解较少。

Myrrix 36 是一个完整、实时、可扩展的推荐系统，使用 Apache Mahout TM 构建（见第 5 节）。它可作为 PaaS 通过 RESTful 接口访问。一旦有新数据可用，它能够增量更新模型。它分为 2 层 - Serving（开源且免费）和 Computation（基于 Hadoop）- 也可部署在本地，既可同时部署两层，也可只部署其中一层。

Prior Knowledge Veritable API 37 提供 Python 和 Ruby 接口；用户将数据上传到其服务器，并使用 Markov Chain Monte Carlo 采样器构建预测模型。它们运营基于 Amazon WS 的云基础设施。SalesForce.com 于 2012 年底收购了 Prior Knowledge。

Prediction Appliance 的 Predictobot 38 也旨在让机器学习建模更容易。用户将上传数据电子表格，回答几个问题，然后下载包含预测模型电子表格。它将把预测建模带给任何具备电子表格技能的人。该业务仍处于保密模式。

7.1 作为 SaaS 的文本挖掘

由于社交媒体技术爆炸式增长，例如博客平台（WordPress.com、Blogger 等）、微博（Twitter）或社交网络（Facebook、Google+），人们对以服务形式交付给客户的文本挖掘和自然语言处理（NLP）解决方案越来越感兴趣。因此，我们专门用一个完整小节将文本挖掘的软件/平台即服务解决方案归为一组。在评述可用解决方案之前，先简要介绍 NLP 和文本挖掘会有所帮助。

虽然 NLP 使用受语言学启发的技术（利用形式语法和词典中的信息对文本进行句法解析，然后对生成的信息进行语义解释并用于提取信息）来深入分析文档，

31 <http://precog.com>

32 <https://developers.google.com/prediction/>

33 <https://developers.google.com/storage/>

34 <https://eigendog.com/#home>

35 <http://metamarkets.com/>

36 <http://myrrix.com>

37 <http://priorknowledge.com>

38 <http://predictobot.com>

文本挖掘出现得更晚，使用信息检索、统计学和机器学习领域发展出的技术。与 NLP 不同，文本挖掘的目标不是理解文本中“说了什么”，而是从大量文档中提取模式。文本挖掘的功能包括概念/实体抽取、文本聚类、摘要或情感分析。

需要处理的文档大小和数量，加上实时处理约束，推动了能够满足高要求用户需求的新型分布式工具包的发展。网站运营者希望以最低投资和较低维护成本向访问者提供文本挖掘功能。因此，越来越多提供商通过 RESTful Web 服务提供文本挖掘服务，使客户免于昂贵的基础设施和部署。

我们并不打算对文本挖掘 PaaS 提供商做穷尽式综述，下面将提及其中几个：

AlchemyAPI 39 是一个基于云的文本挖掘 SaaS 平台，提供所有文本挖掘平台中最全面的一组 NLP 能力，包括：命名实体抽取、情感分析、概念标注、作者抽取、关系抽取、网页清理、语言检测、关键词抽取、引文抽取、意图挖掘和主题分类。AlchemyAPI 使用深层语言解析、统计自然语言处理和机器学习来分析你的内容，抽取语义元数据：关于人物、地点、公司、主题、语言等的信息。它提供 RESTful API 端点、所有主要编程语言的 SDK，响应可编码为多种格式（XML、JSON、RDF）。对于有特定数据安全需求或监管约束的组织，它提供将解决方案安装在自有环境中的可能性。

NathanApp TM 40 是 AI-one 的通用机器学习 PaaS，也可作为 NathanNode TM 部署在本地。与 Topic-Map per 一样，它非常适合通过学习词语上下文来学习任何人类语言的含义，只是速度更快且部署灵活性更高。NathanApp 是使用 JavaScript 和 JSON 的 RESTful API。

TextProcessing 41 也是一个 NLP API，支持词干提取和词形还原、情感分析、标注和块抽取、短语抽取以及命名实体识别。这些服务通过 RESTful API 端点开放并免费提供（限量使用），客户端库包括 Java、Python、

39 <http://www.alchemyapi.com>

40 <http://ai-one.com>

41 <http://text-processing.com>

Ruby、PHP 和 Objective-C，响应以 JSON 编码，并提供 Python NLTK 演示以实现陡峭的学习曲线。出于商业用途，客户可通过 Mashape.com 购买月度订阅。

Yahoo! Content Analysis Web Service 42 可检测非结构化内容中的实体/概念、类别和关系。它按总体相关性对检测到的实体/概念排序，在可能情况下将其解析为 Wikipedia 页面，并用相关元数据标注标签。该服务作为 YQL 表提供，响应为 XML 格式。它可免费用于非商业用途。

本节介绍了在某种程度上处理机器学习问题的 PaaS 解决方案。由于文本挖掘问题在 ML PaaS 格局中不断扩散，本文专门设置了一个子节。我们注意到 Yahoo! 或 Google 等大玩家，也注意到许多获得数百万美元融资的初创公司。它们为 Web 开发者提供了将 ML 智能轻松集成到其网站中的可能性。这些服务更强调易用性而非所提供的功能，因此只能有限地调整服务背后的算法。因此，它们适合具有基本 ML 需求的用户，但不够灵活，难以处理更高级的问题。

8 结论与未来工作

我们的主要发现总结如下：

(1) MapReduce (MR) 和 Message Passing Interface (MPI) 等用于表达大规模并行性的现有编程范式，是实现 ML-DM 算法的事实选择。由于 MR 能够处理大型数据集且内置对故障的恢复能力，越来越多的关注投入到 MR 上。

(2) 分布式环境中的机器学习有不同方法，为不关注分布式环境的传统 ML 和统计应用提供了可行且具有成本效益的替代方案 [14]。

(3) 现有解决方案要么面向有经验、熟练的计算机科学家、数学家、统计学家，要么面向满足于没有（或很少）算法调优可能性的新手用户。现有分布式 ML-DM 解决方案在很大程度上缺少最终用户支持和指导。

在评述市场上 30 多种不同产品之后，我们认为仍有空间提供一种可扩展、

42 <http://developer.yahoo.com/search/content/V2/contentAnalysis.html>

易于使用和部署的 ML-DM 解决方案，置于云计算范式背景下，面向编程或统计经验较少，但愿意运行和调优高级科学 ML 任务的最终用户，例如医学、金融、电信等领域的研究人员和实践者。在这方面，我们的未来计划包括原型化这样一个分布式系统，它依赖现有分布式 ML-DM 框架，但增强其可用性和用户友好性功能。

致谢

本工作得到 EC-FP7 项目 FP7REGPOT-2011-1 284595 (H OST) 支持。

参考文献

[1] R. Bekkerman, M. Bilenko 和 J. Langford (编辑) - Scaling up Machine Learning, Cambridge University Press, 2012, 摘要见 <http://people.cs.umass.edu/~ronb/scaling-up-machine-learning.htm>

[2] M. Budiu, D. Fetterly, M. Isard, F. McSherry 和 Y. Yu - 使用 DryadLINQ 的大规模机器学习, 载于 R. Bekkerman, M. Bilenko 和 J. Langford (编辑) - Scaling up Machine Learning, Cambridge University Press, 2012

[3] S. Charrington - 三种新工具将机器学习洞察带给大众, 2012 年 2 月, Read Write Web, <http://www.readwriteweb.com/hack/2012/02/three-new-tools-bring-machine.php>

[4] W. Eckerson - 大数据新技术, <http://www.b-eye-network.com/blogs/eckerson/archives/2012/11/new-technologie.php> (2012)

[5] D. Harris - 5 家可能改变大数据面貌的低调初创公司, 2012 年 1 月, <http://gigaom.com/cloud/5-low-profile-startupsthat-could-change-the-face-of-big-data/>

[6] A. Ghoting, P. Kambadur, E. Pednault 和 R. Kannan - NIMBLE : 在 MapReduce 上实现并行数据挖掘和机器学习算法的工具包, KDD 11

[7] A. Ghoting 等 - SystemML : mapreduce 上的声明式机器学习。载于 2011 IEEE 27th International Conference on Data Engineering, ICDE 11 论文集, 第 231-242 页, Washington, DC, USA, 2011

[8] S. Hido - Jubatus : 面向大数据的分布式在线机器学习框架, XLDB Asia, 北京, 2012 <http://www.slideshare.net/JubatusOfficial/distributed-online-machine-learning-framework-for-big-data>

[9] M. Isard 等 - Dryad : 由顺序构建块组成的分布式数据并行程序。载于 SIGOPS Operating System Review, 2007

[10] KD Nuggets Survey 2012 ■ <http://www.kdnuggets.com/software/suites.html>

[11] Y. Low, J. Gonzalez, A. Kyrola, D. Bickson, C. Guestrin, J. M. Hellerstein - Distributed GraphLab : 云端机器学习与数据挖掘框架, Proceedings of the VLDB Endowment, Vol. 5, No. 8, 2012 年 8 月, Istanbul, Turkey

[12] S. Owen, R. Anil, T. Dunning, E. Friedman - M about in Action ■ Manning Publications ■ 2011 ■ ISBN 978-1935182689

[13] E. Pednault, E. Yom-Tov, A. Ghoting - IBM Parallel Machine Learning Toolbox, 载于 R. Bekkerman, M. Bilenko 和 J. Langford (编辑) - Scaling up Machine Learning, Cambridge University Press, 2012

[14] D. Pop, G. Iuhasz - 机器学习工具和库综述, Institute e-Austria Timișoara Technical Report, 2011

[15] Rexer Analytics Survey 2011 ■ <http://www.rexeranalytics.com/Data-MinerSurvey-Results-2011.html>

[16] L. Tierney, A. J. Rossini, Na Li - Snow : R System 的并行计算框架, Int J Parallel Prog (2009) 37:78-90, DOI 10.1007/s10766008-0077-2

[17] S. R. Upadhyaya 机器学习的并行方法 - 一项综合综述, Journal of Parallel and Distributed Computing, Volume 73, Issue 3, 2013 年 3 月, Pages 284-292

[18] B. Werther - 大数据的前工业时代, 2012 年 6 月, <http://www.platfora.com/pre-industrialage-of-big-data/>

[19] Y. Yu, M. Isard, D. Fetterly, M. Budiu, U. Erlingsson, P. Kumar Gunda, J. Currey - DryadLINQ : 使用高级语言进行通用分布式数据并行计算的系统, 载于 OSDI, 2008

[20] Apache Hadoop <http://hadoop.apache.org> (2012)

网页,

Daniel Pop 于 2006 年在 West University of Timișoara 获得计算机科学博士学位。他目前是 West University of Timișoara 数学与计算机科学学院计算机科学系高级研究员。研究兴趣涵盖高性能计算和分布式计算技术、机器学习、知识发现与表示以及多智能体系统。他还在 IT 行业拥有丰富经验 (+15 年), 曾应用 SCRUM 和 Kanban 等敏捷软件开发流程。

[21] WibiData How It Works <http://www.wibidata.com/product/how-itworks/> (2012)

Name	Platform	Licensing	Language	Activity
Mahout	Hadoop	Apache 2	Java	High
GraphLab	MPI / Hadoop	Apache 2	C++	High
DryadLINQ	Dryad	Commercial	.NET	Low
Jubatus	ZooKeeper	LGPL 2	C++	Medium
NIMBLE	Hadoop	?	Java	Low
SystemML	Hadoop	?	DML	Low

表 1. ML-DM 的分布式框架