

ar
Xi
v:
16
03
.0
87
67
v1
[
cs
.D
C]
2
9
Ma
r
20
16

机器学习与云计算：分布式与 SaaS 解决方案调研

Daniel Pop

e-Austria 研究所 蒂米什瓦拉 Vasile P â rvan 大
道4号, 300223 蒂米什瓦拉, 罗马尼亚 电子邮箱：d
anielpop@info.uvt.ro

摘要

将流行的机器学习算法应用于海量数据，给机器学习从业者带来了新的挑战。传统的机器学习库在处理超大规模数据集方面表现不佳，因此需要新的方法。利用现代并行计算框架（如 MapReduce、CUDA 或 Dryad）进行并行化变得越来越流行并被广泛接受，催生了一批基于这些框架开发的新机器学习库。我们将简要介绍最突出的工业界与学术界成果，例如 Apache Mahout™、GraphLab 或 Jubatus。

我们将研究云计算范式如何影响机器学习领域。第一个方向是流行的统计工具和库（R 系统、Python）在云端的部署。第二条产品线是通过插件增强现有工具，使用户能够在云端创建 Hadoop 集群并在其上运行作业。接下来是机器学习算法的分布式实现库，以及在本地图部署的复杂数据分析与数据挖掘系统。本次调研关注的最后一种方式是“机器学习即软件即服务”，多家大数据初创公司（以及大型企业）已将各自的解决方案推向市场。

1 引言

鉴于企业、工业与科学领域所收集和可用数据的激增，用于分析这些数据的技术变得愈发重要。如今，待分析的数据不再局限于传感器数据和传统数据库，而是越来越多地涵盖文本文档与网络

页面（文本挖掘、网络挖掘）、空间数据、多媒体数据、关系数据（分子、社交网络）。分析工具让终端用户能够从大量结构化与非结构化数据中挖掘出有意义的模式。通过分析大型数据集，用户可以识别新的收入来源，培养忠诚且盈利的客户关系，并使整个组织更高效、更具成本效益地运行。

知识发现与机器学习的研究融合了计算机科学的经典问题（高效算法、软件系统、数据库）、人工智能与统计学的要素，直至面向用户的议题（可视化、交互式挖掘）。

尽管二十多年来，并行数据库产品（如 Teradata、Oracle 或 Netezza）已提供了实现 ML-DM 算法并行化的手段，但用 SQL 代码表达 ML-DM 算法仍然是一项复杂且难以维护的任务。此外，这些产品的大规模部署成本高昂，在大多数情况下并非可负担的选择。促使范式从关系模型转向其他替代方案的另一个驱动因素是新数据特性。大约五年前，大多数数据本质上是事务性的，由易于放入关系数据库行和列中的数字或字符串数据组成。自那以来，结构化数据呈接近线性增长，而非结构化（如音频和视频）和半结构化数据（如网络流量数据、社交媒体内容、传感器生成的数据等）则呈指数级增长（见图 1）。大多数新数据要么是半结构化格式，即由头部后跟文本字符串组成；要么是纯非结构化数据（照片、视频、音频）。后者文本内容有限，解析和分析更为困难；而半结构化数据则催生了大量非关系型数据存储（NoSQL 数据存储）解决方案，专门用于处理海量数据。因此，过去五年里

本手稿最初于2012年以IEAT技术报告形式发布于 <https://www.ieat.ro/technical-reports>。




图 1. 数据增长趋势

我们已看到研究人员开始将这些新平台（如 NoSQL 数据存储、分布式处理环境（MapReduce）或云计算）用于 ML-DM 的并行化。

此时，值得引用 Platfora 联合创始人 Ben Werther [18] 对当今大数据处理的一个精妙比喻：

“用“工业革命”的话来说，我们正处于大规模生产之前的纯手工时代。preceeded mass production. 这相当于需要请一位专家铁匠来为我们的餐桌锻造刀叉和勺子。”

机器学习本身是一项耗时的任务，因此人们投入大量努力来缩短执行时间。云计算范式及云服务商被证明是加速机器学习平台的有价值替代方案。于是，流行的统计工具环境——如 R、Octave、Python——也迁移到了云端。将它们与云服务商集成主要有两个方向：一种是在云端创建集群并用统计工具进行引导；另一种是为统计环境增加插件，使用户能够在云端创建 Hadoop 集群并在其上运行作业。

R、Octave、Maple 等环境为数据分析提供底层基础设施，一旦由云提供商增强，即可应用于大型数据集。机器学习在此基础上发挥作用，通过自动从数据中推断“知识模型”，帮助缺乏/较少统计背景的客户从海量数据中获取有用知识。为满足这一需求，大量初创公司应运而生，其中一些仍处于隐身状态

在过去五年中，可以看到尚未成为平台、但向客户提供机器学习服务或大数据分析服务的举措。这些举措可以是 PaaS/SaaS 平台，也可以是可部署在私有环境中的产品。

回顾文献与市场，我们可以得出结论：ML-DM 有多种风格。我们将这些方法划分为 5 个不同的类别：

- 云端机器学习环境——在云端创建计算机集群，并用统计工具对其进行引导。⇒ 第 3 节。
- 机器学习工具插件——通过插件增强统计工具，使用户能够在云端创建 Hadoop 集群并在其上运行 ML 作业。⇒ 第 4 节。
- 分布式机器学习库——面向分布式环境（Hadoop、Dryad 等）的并行化 ML 算法实现集合。⇒ 第 5 节。
- 复杂机器学习系统——需要部署在私有数据中心（或云端）并提供高性能数据挖掘与分析的产品。⇒ 第 6 节。
- 机器学习即服务提供商——PaaS/SaaS 解决方案，允许客户通过网络服务访问 ML 算法。⇒ 第 7 节。

本文其余部分结构如下：下一节介绍近期相关研究，随后用 5 个章节分别讨论上述每一类内容。文章最后给出结论与未来计划。

2 相关研究

自 1995 年以来，针对共享或分布式系统的 ML-DM 算法并行化已提出许多实现方案。欲了解全面研究，读者可参考近期综述 [17]。我们的工作聚焦于支持大规模、分布式实现最新 ML-DM 算法的框架、工具包和库。在此方面，我们提到一本近期关于大规模机器学习的著作 [1]，其中既介绍了高度可扩展 ML 实现的通用框架（如 DryadLINQ 或 IBM PMLT），也介绍了在这些平台上对 ML 技术（如集成决策树、SVM、k-Means 等）的具体实现。该书收录了来自业界领袖（Google、HP、

IBM、Microsoft）和学术界（伯克利、纽约大学、加州大学等）的贡献。

最近的文章，如 S. Charrington [3]、W. Eckerson [4] 和 D. Harris [5] 的综述，回顾了不同的大规模机器学习解决方案提供商，这些公司正试图提供更好的工具和技术，其中大多数基于 Hadoop 基础设施，以推动大数据这一新兴行业的发展。它们致力于改善用户体验、产品推荐或适用于金融、电信、零售、广告或媒体的网站优化。

3 云端机器学习环境

此类提供商利用 Amazon EC2、Rackspace 等公有云供应商搭建计算机集群，并预装统计软件，首选 R 系统、Octave 或 Maple。这些方案为客户提供云端可扩展的高性能资源，客户无需自行安装和管理集群。

Cloudnumbers.com¹ 利用 Amazon EC2² 供应商部署预装科学计算软件（如 R 系统、Octave 或 Maple）的计算机集群。客户可通过网页界面创建个人工作空间、配置并监控集群、上传数据集或连接公共数据库。除云供应商的默认功能外，Cloudnumbers 还提供高安全标准，对数据传输和存储进行加密。总体而言，这是一个云端 HPC 平台，创建简单，维护无忧。

CloudStat³ 是基于 R 系统构建的云集成开发环境，通过两种用户界面提供功能：面向熟悉 R 语言用户的控制台，以及面向无 R 编程技能用户的应用程序——采用点击式表单界面。此外，还有一个 CloudStat 应用商店，用户可以从不断增长的仓库中选择应用。

Opani⁴ 提供与 Cloudnumbers.com 类似的服务，但额外帮助客户根据其需求调整集群规模：数据大小和处理该数据的时间范围。他们使用 Rackspace 的基础设施，并支持 R 系统、Node 和 Python 等环境，捆绑提供。

1 <http://cloudnumbers.com>
2 <http://aws.amazon.com/ec2/>
3 <http://cs.croakun.com>
4 <http://opani.com>
5 <http://rackspace.com>

借助 map/reduce、可视化、安全和版本控制包，在 Opani 中命名为仪表板的数据分析结果可以轻松地从桌面或移动设备进行可视化和共享。

这类方法功能强大且灵活，为用户提供在云端运行复杂机器学习与数据挖掘应用的可能性。用户无需自行配置分布式科学计算环境，同时仍可使用自己偏好的开发环境。另一方面，这些工具的用户需要具备丰富的编程经验和扎实的统计学知识。或许由于受众有限，该类别中稳定的提供商比其他类别少，其中一些（如 CRdata.org）在上线不久后便停止了运营。

4 机器学习工具插件

在这一类别中，统计应用（如 R 系统、Python）通过插件扩展，使用户能够在云端创建 Hadoop 集群，并在其上对大型数据集运行耗时作业。R 受到的关注最多，已有多款扩展；相比之下，Python 在分布式处理方面的投入直到最近才逐渐增加。本节将介绍若干面向 R 和 Python 的解决方案。

RHIPE⁶ 是一个 R 包，它为 R 实现了 map/reduce 框架，使 R 环境能够访问 Hadoop 安装。通过特定的 R 函数，用户可以在 Hadoop 集群上启动 map/reduce 作业，随后结果从 HDFS 中检索。

Snow⁷ [16] 及其变体（snowfall、snowFT）实现了一个框架，能够表达一类重要的并行计算，并且易于在 R 这样的交互式环境中使用。它支持三种集群类型：基于套接字的、MPI 和 PVM。

R 的 Segue⁸ 项目使得在 R 环境中针对 Amazon Elastic Map Reduce⁹ 上的弹性集群运行 map/reduce 作业变得更加容易。

Anaconda¹⁰ 是由 Continuum Analytics 提供的可扩展 Python 数据分析和科学计算平台。它是一个软件包集合（NumbaPro -

6 <http://www.stat.purdue.edu/~sguha/rhipe/doc/html/index.html>

7 <http://cran.r-project.org/web/packages/>

可用包名称.html

8 <http://code.google.com/p/segue/>

9 <http://aws.amazon.com/elasticmapreduce/>

10 <https://store.continuum.io/cshop/anaconda>

11 <http://continuum.io>

快速的多核和GPU加速计算、IOPro——快速数据访问，以及wiseRF Pine——随机森林的多核实现，这些功能共同实现了大规模数据的管理、分析与可视化等。它可以作为完整的Python发行版安装，也可以接入现有的安装环境。

由于 R 系统在机器学习与数据挖掘从业者中极受欢迎，并在过去两年成为此类任务的首选工具 [15, 10]，近期已出现将其耗时流程并行化到可扩展分布式框架（Hadoop）上的努力。相比云端机器学习，这种方法更受青睐，因为它可以复用研究或工业（私有）数据中心的现有基础设施。据我们所知，目前尚无针对 Mathematica、Maple 或 Matlab/Octave 等同类数学工具的类似方案，除了 Mathematica 的 HadoopLink 12。此类解决方案的受众在编程语言、数学、统计及机器学习算法方面均具备高水平的专业能力。

5 分布式机器学习库

该类别提供可在多种分布式环境（Hadoop、Dryad、MPI）上运行的复杂库。用户既可以直接使用现成的算法，也可以实现自己的算法，并在计算机集群上以并行模式运行。这些解决方案不集成或使用统计/数学软件，而是提供包含经过优化的、最先进的机器学习与数据挖掘方法和算法的独立软件包。

Apache Mahout TM 13 [12] 是 Apache 的一个项目，旨在 Hadoop 平台 [20] 上提供分布式或其他可扩展机器学习算法的免费实现。它最初是一组独立的“无 Hadoop”组件集合，例如“Taste”协同过滤。其目标是构建可扩展的机器学习库，其中“可扩展”具有更广泛的含义：

- 可扩展到合理规模的数据集。Mahout 的核心聚类、分类和基于批处理的协同过滤算法均基于 Apache Hadoop [20] 实现，采用 map/reduce 范式。然而，它并不限制贡献者必须提供基于 Hadoop 的实现：在单节点或非 Hadoop 集群上运行的贡献同样受欢迎。核心库经过高度优化，以允许

也能为非分布式算法带来良好性能。

- 可扩展，支持多种业务场景。Mahout 采用商业友好的 Apache 软件许可证发布。

- 可扩展的社区。Mahout 的目标是打造一个活跃、响应迅速且多元化的社区，以促进对项目本身及潜在用例的讨论。

目前 Mahout 主要支持四种用例：

- 推荐挖掘：根据用户行为，尝试找出用户可能喜欢的物品
- 聚类：例如将文本文档分组，形成主题相关的文档集合
- 分类：从已有的已分类文档中学习特定类别文档的特征，并能够将未标注的文档分配到（希望）正确的类别。

- 频繁项集挖掘接收一组物品集合（查询会话中的词条、购物车内容），并识别哪些单个物品经常一起出现。

与图处理平台 Apache Giraph 14 等倡议的集成正在积极讨论中。该项目背后有一个活跃的社区。

GraphLab 15 [11] 是一个面向云端机器学习与数据挖掘（ML-DM）的框架。尽管像 MapReduce 这样的高级数据并行框架简化了大规模数据处理系统的设计与实现，它们并不能自然或高效地支持许多重要的数据挖掘与机器学习算法，可能导致学习系统效率低下。为填补这一关键空白，GraphLab 提供了一种抽象，能够自然地表达异步、动态的图并行计算，同时保证数据一致性，并在共享内存和分布式环境中均获得高度并行性能。它用 C++ 编写，可直接访问 Hadoop 分布式文件系统（HDFS）[20]。作者报告称，其性能比同类方法高出一个数量级。

DryadLINQ 16 [19, 2] 是微软开发的 LINQ（语言集成查询 17）子系统

14 <http://incubator.apache.org/giraph/>

15 <http://graphlab.org>

16 <http://research.microsoft.com/en-us/projects/DryadLINQ/>

17 <http://msdn.microsoft.com/netframework/future/linq/>

12 <https://github.com/shadanan/HadoopLink>

13 <http://mahout.apache.org>

基于 Dryad [9] 的研究, Dryad 是一个用于执行数据并行应用的通用架构。它继承了 Dryad 的 DAG 抽象, 支持实现数据处理算法。DryadLINQ 程序是由 LINQ 表达式组成的顺序程序, 这些表达式对数据集执行任意无副作用的转换, 可以使用标准的 .NET 开发工具进行编写和调试。DryadLINQ 系统自动且透明地将程序的数据并行部分翻译为分布式执行计划, 并将其传递给 Dryad 执行平台, 确保该计划的高效可靠执行。作者展示了作业执行时间随所用计算机数量接近线性扩展的能力。尽管基于 DAG 的抽象允许丰富的计算依赖关系, 但它并不能自然地表达机器学习与数据挖掘中普遍存在的迭代、数据并行、任务并行和动态数据驱动算法。

Jubatus 18 [8] 于 2011 年 4 月启动, 是一个基于分布式架构的在线/实时机器学习平台。与 Mahout TM 相比, 它是下一代平台, 提供流处理和在线学习。在在线 ML 中, 模型通过快速且内存占用低的算法, 随着每个数据样本的到来而持续更新。它无需数据存储或共享, 仅需模型混合。支持分类问题 (Passive Aggressive (PA)、Confidence Weighted Learning、AROW)、基于 PA 的回归、最近邻 (LSH、MinHash、Euclid LSH)、推荐、异常检测 (基于 NN 的 LOF) 以及图分析 (最短路径、PageRank)。为了高效支持在线学习, Jubatus 在本地模型上执行更新, 随后各服务器将其模型差异发送出去, 这些差异被合并后再分发给所有服务器。借助所有服务器的协同工作, 混合模型逐步改进。

IBM 并行机器学习工具箱 19 [13] (PMLT) 是 IBM 海法实验室机器学习小组与 IBM Watson 实验室数据分析部门的联合成果, 提供在多种处理器环境或多线程机器上执行数据挖掘与机器学习算法的工具。该工具箱包含两个主要组件: 一个用于运行用户自定义机器学习算法的 API, 以及若干预编程算法, 这些算法既作为示例, 也可用于比较。预编程算法包括支持向量机 (SVM) 分类器的并行版本、线性回归等。

变换回归、最近邻、k-means、模糊k-means、核k-means、PCA 与核PCA。PML工具箱的一大优势是能够在多种操作系统和硬件平台上运行, 从多核笔记本到BlueGene等超级计算机。这是因为它内置了并行化基础设施, 将并行通信、控制与数据访问完全与学习算法的实现分离。该设计使算法开发者只需关注算法本身, 而无需处理底层并行化问题; 同时也让同一套算法代码无需修改即可在串行或并行、多种硬件架构上部署。工具箱以流行的MPI库为基础, 采用C++编写。尽管我们努力追踪该项目的最新动态, 但自2007年以来未见任何更新, 仅在文献[1] (2012) 中有一章提及。此外, 该工具箱适用于并行环境, 而非分布式环境。

NIMBLE [6] 是 IBM 研究实验室开发的并行机器学习工具箱的后续项目。它提供了一个多层框架, 开发者可以将其 ML-DM 算法表示为任务。任务随后被传递到下一层——一个与架构无关的层, 该层由一个任务 DAG 队列和一个展开该队列的工作线程池组成。再下一层是与架构相关的层, 将上层通用实体转换为各种运行时。目前, NIMBLE 仅支持在 Hadoop 平台 [20] 上执行。其他平台 (如 Dryad [9]) 也是合适的候选, 但尚未支持。该框架的优势包括:

- 更高层次的抽象, 隐藏了大多数分布式和并行编程范式 (MR、MPI 等) 的低级控制和编排细节, 使程序员能够使用可复用的 (串行和并行) 构建块来组合并行 ML-DM 算法

- 可移植性: 为依赖架构的层提供特定实现, 同一段代码可在多种分布式运行时上执行。

- 高效性与可扩展性: 得益于 DAG 任务与协同调度的优化, 文献 [6] 在 Hadoop 运行时上的结果表明, 随着数据集规模与维度的增加, 加速比得到提升。

18 <http://jubat.us/>
19 <https://www.research.ibm.com/haifa/projects/verification/mltoolbox/index.html>

SystemML [7], 由 IBM 研究实验室以 NIMBLE 和 PML T 名义开发, 提出了一种类似 R 的语言 (声明式机器学习语言), 其中包含线性代数原语, 并展示了如何将其优化并编译为 MapReduce。他们在三种 (组非负矩阵分解、线性回归、PageRank) 机器学习算法上, 针对不同数据量和 Hadoop 集群规模进行了广泛的性能评估。

表 5 汇总了所调研的平台。可以看出, 由于 Hadoop 作为分布式处理模型被广泛采用和使用, Java 成为首选环境。好消息是, 最活跃、最有生命力的解决方案都是开源的。这类产品的目标受众是需要快速、可扩展的分布式解决方案来应对 MLDM 问题的程序员、系统开发者和机器学习专家。

6 复杂机器学习系统

本节介绍了几种商业智能和数据分析解决方案, 它们具备一组共同特征: (i) 均可部署在本地或云端集群; (ii) 提供丰富的图形工具, 用于分析、探索和可视化大量数据; (iii) 仅公开相当有限的机器学习与数据挖掘功能, 通常仅限于预测模型; (iv) 利用 Apache Hadoop [20] 作为处理引擎和/或存储环境。在数据集成与处理方式、支持的数据源以及系统复杂性方面存在差异。以下是最知名的方案:

Kitenga Analytics 20 最近被戴尔收购, 是一款原生 Hadoop 应用, 提供可视化 ETL、基于 Apache Solr T M 21 的搜索、自然语言处理、基于 Apache Mahout 的数据挖掘以及高级可视化功能。它为需要强大分析工具箱的资深分析师打造了一个大数据环境, 所有功能都通过易用的界面提供, 无需理解复杂编程或 Apache Hadoop 技术栈本身。

Pentaho Business Analytics 22 提供完整的大数据 Analytics 解决方案, 支持分析流程的所有阶段, 从预处理到高级数据探索与可视化。它提供 (i) 完整的可视化设计工具, 加速数据准备—

20 <http://www.quest.com/news-release/quest-software-expands-its-big-data-solution-with-new-hadoop-cte-102012818658.aspx>

21 <http://lucene.apache.org/solr/>

22 <http://www.pentaho.org>

(ii) 从 NoSQL 和关系数据库进行数据集成, (iii) 在 Hadoop 平台上分布式执行 [20], (iv) 即时交互式分析 (无需编码, 无需 ETL (抽取、转换、加载)), 以及 (v) 商业分析平台: 数据发现、探索、可视化和预测分析。Pentaho 解决方案的主要特点包括:

- 基于 MapReduce 的数据处理
- 可针对不同 Hadoop 发行版 (如 Cloudera、Hadoop 等) 进行配置
- 数据可加载并处理到 Hadoop HDFS、HBase 23 或 Hive 24 中
- 支持 Pig 脚本
- 原生支持大多数 NoSQL 数据库, 例如 Apache Cassandra、DataStax、Apache HBase、MongoDB、10gen 等
- 通过与原生 SQL 方言和并行批量数据加载器的深度集成, 为分析型数据库 (如 Teradata、MonetDB、Netezza 等) 实现性能优化的数据分析、报告和数据集成
- 与 LexisNexis Risk Solutions 的 HPCC (高性能计算集群) 集成
- 支持 PMML (预测模型标记语言) 的导入/导出
- Pentaho Instaview, 一款可视化应用, 可缩短部署数据分析解决方案所需的时间, 并通过三个简单步骤帮助新手用户洞察其数据: 选择数据源、自动准备分析所需数据、可视化并探索已构建的模型。
- Pentaho Mobile - 面向 iPad 的应用, 为业务用户提供交互式商业分析

其生态系统由多个强大的系统组成, 每个系统本身都是一个复杂的项目:

Pentaho BI 平台/服务器: BI 平台是一个框架, 提供身份验证、日志记录、审计和规则引擎等核心服务; 它还拥有一个解决方案引擎, 可集成所有其他系统 (报表、分析、集成和数据挖掘); BI 服务器是该平台最知名的实现, 作为基于 Web 的报表运行

23 <http://hbase.apache.org>

24 hive.apache.org

25 <http://hpccsystems.com>

管理系统、应用集成服务器和轻量级工作流引擎。

基于 JFreeReport 的 Pentaho Reporting 是一套开源工具——包括 Pentaho Report Designer、Pentaho Reporting Engine、Pentaho Reporting SDK 以及与整个 Pentaho BI 平台共享的通用报表库——允许用户从多种数据源创建关系型和分析型报表，并以多种格式（HTML、PDF、Excel 等）输出结果。

Pentaho Data Integration (Kettle) 采用元数据驱动的方法，通过直观、图形化的拖放设计环境，提供强大的 ETL 功能；

Pentaho Analysis Service (Mondrian) 是一款支持实时数据分析的在线分析处理 (OLAP) 服务器；

Pentaho Data Mining (Weka) 是一套用于分类、回归、聚类 and 关联规则的机器学习算法集合；

Platfora 26 提供内存中的商业智能，无需单独的数据仓库或 ETL。其基于 HTML5 的可视化界面允许业务用户分析数据，结果可在用户间轻松共享。它依赖 Hadoop 集群，可在本地部署或云服务商（Amazon EMR 和 S3）上运行。主要聚焦 BI 功能，如丰富的可视化类型（图表、绘图、地图）和切片切块操作，同时提供预测分析框架。

Skytree Server 27 是一款通用机器学习与数据分析系统，支持来自关系型数据库、Hadoop 系统或平面文件的数据，并提供常用统计包和机器学习库的连接器。支持的机器学习方法包括：支持向量机 (SVM)、最近邻、K 均值、主成分分析 (PCA)、线性回归、两点相关性和核密度估计 (KDE)。Skytree Server 可与分析前端（如 Web 服务或统计与机器学习库 R、Weka）连接，进行数据可视化。其部署选项包括云提供商或基于 Linux 机器的专用集群。它还通过一个简单的公式 (Analytics Requirements Index) 帮助客户估算所需集群规模。

Wibidata 28 是一个基于 Apache 开源软件栈的复杂解决方案，结合了 Hadoop、HBase 和 Avro 以及专有组件。WibiData 的机器学习库提供

立即开始构建复杂数据处理流水线的工具。WibiData 还提供图形化工具，可将其分布式数据仓库中的数据导出到任何关系数据库 [21]。为了简化使用 Hadoop 的数据处理，WibiData 引入了生产者 (producers)——更新表中行的计算函数，以及收集器 (gatherers)——弥合 WibiData 表与 Hadoop MapReduce 引擎处理的键值对之间差距的概念。

我们意识到无法涵盖商业智能和大数据分析领域的所有解决方案提供商。我们尽力覆盖了那些在应用中也提供机器学习组件的厂商；而仅专注于大数据分析的其他厂商（如 Alteryx、SiSense、SAS 或 SAP）则被排除在本次调研之外。此类解决方案主要面向业务用户，这些用户需要快速、轻松地从其数据中提取洞察，是计算机或统计学背景较少用户的理想选择。

7个面向机器学习的软件即服务提供商

本节重点介绍面向机器学习问题的平台即服务或软件即服务提供商。它们主要通过 RESTful 接口提供服务，少数情况下（如 Myrrix）也可本地部署，这与上一节主要面向私有数据中心部署的解决方案形成对比。在这些系统中，预测建模是最受欢迎的机器学习问题类别 (BigML、Google Prediction API、Eigendog)。本研究未纳入基于 Hadoop 的 SQL 解决方案提供商（例如 Cloudera Impala、Hadapt、Hive），因为它们的主要目标并非机器学习与数据挖掘，而是利用 Hadoop 分布式架构实现关系数据的快速、弹性、可扩展 SQL 处理。

BigML 29 是一种机器学习的 SaaS 方案。用户可设置数据源，创建、可视化并共享预测模型（目前仅支持决策树），并利用模型生成预测。所有操作均可通过 Web 界面完成，也可使用 REST API 以编程方式实现。

BitYota 30 是一家成立于 2012 年的新兴初创公司，提供大数据仓储的 SaaS 解决方案。除整合来自不同来源的数据（关系型、NoSQL、HDFS）外，它还允许客户使用 SQL92 执行统计与汇总查询，运行标准 R 统计，以及用 JavaScript、Perl 或

26 <http://platfora.com>

27 <http://skytree.net>

28 <http://wibidata.com>

29 <http://bigml.com>

30 <http://bityota.com>

Python 在并行分析引擎上运行，通过与主流 BI 工具和仪表板集成实现结果可视化。

Precog 31 拥有更完善的 SaaS 解决方案，由 Precog 数据库、Quirrel 语言、ReportGrid 和 LabCoat 工具组成。Precog 的核心是一个原创的（不基于 Hadoop 或其他 NoSQL）、无模式、列式数据库，专为存储和分析半结构化的测量数据而设计，例如事件（用户点击、互动和购买）、传感器数据、活动流数据、事实以及其他无需可变更新的数据。Precog 的功能通过 REST API 提供，但也提供 JavaScript、Python、PHP、Ruby、Java 或 C# 的客户端库。LabCoat 是一个用于创建和管理 Quirrel 查询的 GUI 工具。Quirrel 是一种高度表达的数据分析语言，可轻松在数据库内完成分析、统计和机器学习，适用于任何类型的测量数据。结果支持 JSON 或 CSV 格式。ReportGrid 是一个 HTML5 可视化引擎，可交互式或编程方式构建报告和图表。

Google Prediction API 32 是 Google 基于云端的机器学习工具，可帮助您分析数据。它与存储训练数据的 Google Cloud Storage 33 紧密集成，并通过 RESTful 接口提供服务，还提供 Java、JavaScript、.NET、Ruby、Python 等语言的客户端库供程序员调用。第一步需要用数据训练模型，目前支持的模型包括分类和回归。模型构建完成后，可查询该模型以获得对新实例的预测。向已训练模型添加新数据称为流式训练（Streaming Training），也得到了良好支持。最近新增了 PMML 预处理功能，即 Prediction API 支持使用 PMML 4.0 语法指定的 PMML 转换对数据进行预处理；但不支持导入包含数据的完整 PMML 模型。创建的模型可以作为托管模型在市场中共享。

EigenDog 34 是一项可扩展的预测建模服务，托管在 Amazon EC2（计算）和 S3（数据与模型存储）平台上。它利用 Weka 的 ARFF 格式数据构建决策树模型。用户可通过 API 或供应商提供的开源库，以二进制格式下载模型并集成到自己的应用中。

Metamarkets 35 自称是数据科学即服务提供商，帮助用户从大型数据集中获得洞察。他们为最终用户提供快速、即席的数据调查能力，以便基于统计模型以直观、交互和协作的方式发现新的、独特的异常并捕捉数据流中的趋势。他们主要面向对统计和机器学习了解较少的业务人员。

Myrrix 36 是一个完整、实时、可扩展的推荐系统，基于 Apache Mahout™ 构建（见第 5 节）。它通过 RESTful 接口作为 PaaS 提供服务，可在新数据到来时增量更新模型。系统分为两层——服务层（开源且免费）和计算层（基于 Hadoop）——均可本地部署，可单独或同时部署。

Prior Knowledge Veritable API 37 提供 Python 和 Ruby 接口；将数据上传至其服务器后，可使用马尔可夫链蒙特卡洛采样器构建预测模型。他们曾基于 Amazon WS 运行云基础设施。SalesForce.com 于 2012 年底收购了 Prior Knowledge。

Predictobot 38 由 Prediction Appliance 推出，同样旨在让机器学习建模变得更简单。用户只需上传数据电子表格，回答几个问题，即可下载包含预测模型电子表格。它希望让任何具备制作电子表格技能的人都能进行预测建模。该公司目前仍处于隐身模式。

7.1 作为 SaaS 的文本挖掘

由于社交媒体技术的爆炸式增长，例如博客平台（WordPress.com、Blogger 等）、微博（Twitter）或社交网络（Facebook、Google+），人们对以服务的形式向客户提供的文本挖掘和自然语言处理（NLP）解决方案的兴趣日益增加。因此，我们专门用一个小节来汇总面向文本挖掘的软件/平台即服务解决方案。在回顾可用解决方案之前，先简要介绍一下 NLP 和文本挖掘是有帮助的。

NLP 使用受语言学启发的技术（利用形式语法和词汇信息对文本进行句法解析，然后对结果进行语义解释并用于信息提取）来深入分析文档，

31 <http://precog.com>

32 <https://developers.google.com/prediction/>

33 <https://developers.google.com/storage/>

34 <https://eigendog.com/#home>

35 <http://metamarkets.com/>

36 <http://myrrix.com>

37 <http://priorknowledge.com>

38 <http://predictobot.com>

文本挖掘是较新的领域，采用信息检索、统计学和机器学习领域开发的技术。与自然语言处理不同，文本挖掘的目的不是理解文本中“说了什么”，而是从大量文档中提取模式。其功能包括概念/实体抽取、文本聚类、摘要或情感分析。

需要处理的文档规模和数量，以及实时处理的限制，促使开发新型分布式工具包，以满足高要求用户的需求。网站运营商希望以最低投资和低维护成本为访客提供文本挖掘功能，因此越来越多供应商通过 RESTful Web 服务提供文本挖掘服务，为客户节省昂贵的基础设施和部署成本。

尽管并不打算提供一份详尽的文本挖掘 PaaS 提供商调查，我们仍将在下面提到其中几家：

AlchemyAPI 39 是一个基于云端的文本挖掘 SaaS 平台，提供任何文本挖掘平台中最全面的 NLP 能力，包括：命名实体抽取、情感分析、概念标注、作者抽取、关系抽取、网页清洗、语言检测、关键词抽取、引语抽取、意图挖掘和主题分类。AlchemyAPI 利用深度语言解析、统计自然语言处理和机器学习来分析您的内容，提取语义元数据：有关人物、地点、公司、主题、语言等信息。它提供 RESTful API 端点、所有主流编程语言的 SDK，并且响应支持多种格式（XML、JSON、RDF）。对于有特殊数据安全需求或监管约束的组织，可选择将解决方案部署在自己的环境中。

NathanApp TM 40 是 AI-one 的通用机器学习 PaaS，也可以作为 NathanNode TM 本地部署。与 Topic-Map per 类似，它通过上下文学习任何人类语言的含义，速度更快且部署更灵活。NathanApp 是基于 JavaScript 和 JSON 的 RESTful API。

TextProcessing 41 也是一个 NLP API，支持词干提取和词形还原、情感分析、标注与语块提取、短语提取和命名实体识别。这些服务通过 RESTful API 端点开放且免费（有限使用），提供 Java、Python 客户端库。

39 <http://www.alchemyapi.com>

40 <http://ai-one.com>

41 <http://text-processing.com>

Ruby、PHP 和 Objective-C 返回 JSON 编码的响应，并提供 Python NLTK 演示，以实现陡峭的学习曲线。对于商业用途，客户可通过 Mashape.com 购买月度订阅。

Yahoo! 内容分析网络服务 42 在非结构化内容中检测实体/概念、类别和关系。它按整体相关性对检测到的实体/概念进行排序，尽可能将其解析为维基百科页面，并用相关元数据注释标签。该服务以 YQL 表形式提供，响应格式为 XML，可免费用于非商业用途。

本节介绍了在一定程度上解决机器学习问题的 PaaS 解决方案。由于文本挖掘问题在 ML PaaS 领域中日益普及，我们专门用一个小节来讨论它。我们注意到像 Yahoo! 或 Google 这样的巨头，以及许多获得数百万美元投资的初创公司。它们为 Web 开发者提供了在其站点中轻松集成 ML 智能的可能性。易用性优于这些服务所提供的功能，因此调整服务背后算法的选项非常有限。因此，对于具有基本 ML 需求的用户来说，这些是不错的选择，但对于更高级的问题则不够灵活。

8 结论与未来工作

我们的主要发现总结如下：

（1）现有的用于表达大规模并行性的编程范式，如 MapReduce（MR）和消息传递接口（MPI），已成为实现 ML-DM 算法的事实选择。由于 MR 能够处理大型数据集并具备内置的故障恢复能力，越来越多的研究兴趣集中在 MR 上。

（2）分布式环境下的机器学习采用多种方法，为传统 ML 和统计应用提供了可行且具成本效益的替代方案，后者通常不专注于分布式环境 [14]。

（3）现有解决方案要么面向经验丰富的计算机科学家、数学家、统计学家，要么面向满足于无法（或几乎无法）调参的新手用户。终端用户支持与指导在现有分布式 ML-DM 解决方案中普遍缺失。

在评估了市场上 30 多种不同的产品后，我们认为仍有空间实现可扩展的

42 <http://developer.yahoo.com/search/content/V2/contentAnalysis.html>

在云计算范式背景下，为机器学习与数据挖掘提供易于使用和部署的解决方案，面向编程或统计经验较少、但希望运行和调整高级科学机器学习任务的终端用户，例如来自医学、金融、电信等领域的研究人员和实践者。为此，我们的未来计划包括基于现有分布式MLDM框架原型化这样一个分布式系统，并通过增强可用性和用户友好特性对其进行改进。

致谢

本研究由EC-FP7项目FP7REGPOT-2011-1 284595 (HOST) 资助。

参考文献

[1] R. Bekkerman, M. Bilenko与J. Langford (编辑) ——《Scaling up Machine Learning》，剑桥大学出版社，2012年，摘要见<http://people.cs.umass.edu/~ronb/scaling-up-machine-learning.htm>

[2] M. Budiu, D. Fetterly, M. Isard, F. McSherry, 和 Y. Yu - 使用 DryadLINQ 的大规模机器学习，载于 R. Bekkerman, M. Bilenko 和 J. Langford 编，《Scaling up Machine Learning》，剑桥大学出版社，2012

[3] S. Charrington - 三款新工具将机器学习洞察带给大众，2012年2月，Read Write Web, <http://www.readwriteweb.com/hack/2012/02/three-new-tools-bring-machine.php>

[4] W. Eckerson ——《大数据新技术》，<http://www.b-eyenetwork.com/blogs/eckerson/archives/2012/11/new-technologie.php> (2012)

[5] D. Harris ——5家可能改变大数据面貌的低调初创公司，2012年1月，<http://gigaom.com/cloud/5-low-profile-startupsthat-could-change-the-face-of-big-data/>

[6] A. Ghoting, P. Kambadur, E. Pednault 和 R. Kannan —— NIMBLE：在 MapReduce 上实现并行数据挖掘与机器学习算法的工具包，KDD 11

[7] A. Ghoting 等 —— SystemML：基于 MapReduce 的声明式机器学习，发表于2011年IEEE第27届国际数据工程会议论文集，ICDE 11，第231-242页，美国华盛顿特区，2011年

[8] S. Hido - Jubatus：面向大数据的分布式在线机器学习框架，XLDB Asia，北京，2012 <http://www.slideshare.net/JubatusOfficial/distributed-online-machine-learning-framework-for-big-data>

[9] M. Isard 等 —— Dryad：从顺序构建块构建的分布式数据并程序。载于《SIGOPS 操作系统评论》，2007

[10] KD Nuggets 2012 年调查，<http://www.kdnuggets.com/software/suites.html>

[11] Y. Low, J. Gonzalez, A. Kyrola, D. Bickson, C. Guestrin, J. M. Hellerstein —— Distributed GraphLab：云端机器学习与数据挖掘框架，《VLDB 会议录》，第5卷，第8期，2012年8月，土耳其伊斯坦布尔

[12] S. Owen, R. Anil, T. Dunning, E. Friedman ——《Mahout in Action》，Manning出版社，2011年，ISBN 978-1935182689

[13] E. Pednault, E. Yom-Tov, A. Ghoting - IBM 并行机器学习工具箱，载于 R. Bekkerman, M. Bilenko 和 J. Langford 编，《Scaling up Machine Learning》，剑桥大学出版社，2012

[14] D. Pop, G. Iuhasz - 机器学习工具与库综述，e-Austria Timișoara 研究所技术报告，2011

[15] Rexer Analytics 2011 年调查，<http://www.rexeranalytics.com/Data-MinerSurvey-Results-2011.html>

[16] L. Tierney, A. J. Rossini, Na Li —— Snow：R 系统的并行计算框架，《国际并行程序设计杂志》(2009) 37:78-90, DOI 10.1007/s10766008-0077-2

[17] S. R. Upadhyaya, 机器学习并行方法综述，《并行与分布式计算杂志》，第73卷，第3期，2013年3月，第284-292页

[18] B. Werther —— 大数据的前工业时代，2012年6月，<http://www.platfora.com/pre-industrialage-of-big-data/>

[19] Y. Yu, M. Isard, D. Fetterly, M. Budiu, U. Erlingsson, P. Kumar Gunda, J. Currey - DryadLINQ：一种使用高级语言进行通用分布式数据并行计算的系统，OSDI，2008

[20] Apache Hadoop <http://hadoop.p.apache.org> (2012)

网站,

Daniel Pop 于2006年获得蒂米什瓦拉西部大学计算机科学博士学位。他目前是蒂米什瓦拉西部大学数学与计算机科学学院计算机科学系的高级研究员。研究兴趣涵盖高性能计算与分布式计算技术、机器学习与知识发现与表示, 以及多智能体系统。他在IT行业也有超过15年的广泛经验, 曾应用敏捷软件开发流程, 如SCRUM和Kanban。

[21] WibiData 工作原理, <http://www.wibidata.com/product/how-itworks/> (2012)

Name	Platform	Licensing	Language	Activity
Mahout	Hadoop	Apache 2	Java	High
GraphLab	MPI / Hadoop	Apache 2	C++	High
DryadLINQ	Dryad	Commercial	.NET	Low
Jubatus	ZooKeeper	LGPL 2	C++	Medium
NIMBLE	Hadoop	?	Java	Low
SystemML	Hadoop	?	DML	Low

表1. 用于ML-DM的分布式框架